

DeepFool: 一种简洁而精确的对抗攻击方法

寻找最小扰动的几何视角

汇报人

对抗攻击实验课程

June 15, 2026

目录

- 1 背景与动机
- 2 核心思想（几何直觉）
- 3 数学推导
- 4 算法与实现
- 5 实验效果与对比
- 6 讨论与总结

本章内容

- 1 背景与动机
- 2 核心思想（几何直觉）
- 3 数学推导
- 4 算法与实现
- 5 实验效果与对比
- 6 讨论与总结

什么是对抗样本？

核心现象

给一张能被模型正确分类的图像，叠加一个**人眼几乎察觉不到的微小扰动**，模型就会以高置信度把它分错。这个被扰动后的图像称为**对抗样本**。

- 扰动 $\mathbf{r}$ 很小： $\|\mathbf{r}\|$ 接近 0，视觉上与原图无差别。
- 但模型输出 $\hat{k}(\mathbf{x} + \mathbf{r}) \neq \hat{k}(\mathbf{x})$ 。
- 说明深度网络的决策边界在高维空间里非常“贴近”正常样本。

研究意义： 评估模型鲁棒性、理解决策边界、改进训练（对抗训练）。

对抗攻击的形式化定义

对于分类器 f 与样本 $\mathbf{x}$ ，记其预测标签

$$\hat{k}(\mathbf{x}) = \arg \max_k f_k(\mathbf{x}).$$

寻找“最小”对抗扰动可写成优化问题：

$$\Delta(\mathbf{x}; f) := \min_{\mathbf{r}} \|\mathbf{r}\|_2 \quad \text{s.t.} \quad \hat{k}(\mathbf{x} + \mathbf{r}) \neq \hat{k}(\mathbf{x}).$$

- $\Delta(\mathbf{x}; f)$ 度量了样本 $\mathbf{x}$ 到**决策边界**的距离。
- 这个距离越小，说明模型在该点越“脆弱”。
- **DeepFool 的目标：** 高效、准确地求解这个最小扰动。

最经典的攻击 FGSM (Fast Gradient Sign Method) 只走一步：

$$\mathbf{r} = \varepsilon \cdot \text{sign}(\nabla_{\mathbf{x}} J(\theta, \mathbf{x}, y)).$$

- **优点：** 单步、极快，直觉清晰（沿损失上升最快方向推一步）。
- **局限一：** 取 sign 把每个像素都顶到 $\pm\varepsilon$ ，扰动**粗糙且偏大**。
- **局限二：** 不是为“最小扰动”设计的， ε 需要**手动调**。

由此引出 DeepFool


能不能不手调参数，自动找到**刚好越过决策边界**的最小扰动？

本章内容

- 1 背景与动机
- 2 核心思想（几何直觉）
- 3 数学推导
- 4 算法与实现
- 5 实验效果与对比
- 6 讨论与总结

几何直觉：决策边界就是“超平面”

- 在样本附近，把分类器**局部线性化**，决策边界近似为一个个**超平面**。
- 让样本改变类别，最省力的做法是：沿**垂直方向**推到**最近**的那个边界外。
- 这正是“点到平面的最短距离”——线性代数里的经典问题。



在所有相邻类别的边界中，DeepFool 选择**最近**的那条，做垂直投影。

本章内容

- 1 背景与动机
- 2 核心思想（几何直觉）
- 3 数学推导**
- 4 算法与实现
- 5 实验效果与对比
- 6 讨论与总结

二分类：线性分类器（最简单情形）

设二分类器 $f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b$ ，预测 $\hat{k}(\mathbf{x}) = \text{sign}(f(\mathbf{x}))$ 。

样本 $\mathbf{x}$ 到超平面 $\{\mathbf{x} : f(\mathbf{x}) = 0\}$ 的最小扰动，就是**正交投影**：

$$\mathbf{r}_*(\mathbf{x}) = -\frac{f(\mathbf{x})}{\|\mathbf{w}\|_2^2} \mathbf{w}$$

- 方向：沿法向量 $\mathbf{w}$ （边界的垂直方向）。
- 大小： $\|\mathbf{r}_*\|_2 = \frac{|f(\mathbf{x})|}{\|\mathbf{w}\|_2}$ ，正是**点到平面的距离**。
- 这是闭式解，一步到位。

二分类：一般（非线性）分类器

真实网络是非线性的，没有全局超平面。DeepFool 的做法：**反复线性化 + 迭代**。

在当前迭代点 $\mathbf{x}_i$ 把 f 一阶展开：

$$f(\mathbf{x}_i + \mathbf{r}) \approx f(\mathbf{x}_i) + \nabla f(\mathbf{x}_i)^\top \mathbf{r}.$$

令其等于 0，得到这一步的最小扰动：

$$\mathbf{r}_i = - \frac{f(\mathbf{x}_i)}{\|\nabla f(\mathbf{x}_i)\|_2^2} \nabla f(\mathbf{x}_i), \quad \mathbf{x}_{i+1} = \mathbf{x}_i + \mathbf{r}_i.$$

- 每走一步都重新计算梯度（重新线性化），逼近真实弯曲的边界。
- 直到 $\hat{k}(\mathbf{x}_i)$ 改变为止，通常只需 **2-4 步**。

多分类：在所有边界中选最近的一条

对 c 类分类器 $f: \mathbb{R}^n \rightarrow \mathbb{R}^c$ ，记原始标签 $\hat{k}(\mathbf{x}_0)$ 。在迭代点 $\mathbf{x}_i$ ，对每个其他类别 $k \neq \hat{k}(\mathbf{x}_0)$ 定义：

$$\mathbf{w}'_k = \nabla f_k(\mathbf{x}_i) - \nabla f_{\hat{k}(\mathbf{x}_0)}(\mathbf{x}_i), \quad f'_k = f_k(\mathbf{x}_i) - f_{\hat{k}(\mathbf{x}_0)}(\mathbf{x}_i).$$

- $\mathbf{w}'_k$ ：类别 k 与当前类之间“等分边界”的法向。
- f'_k ：当前点相对该边界的“带符号距离量”。

选出**最近**的边界：

$$\hat{l} = \arg \min_{k \neq \hat{k}(\mathbf{x}_0)} \frac{|f'_k|}{\|\mathbf{w}'_k\|_2}.$$

多分类：最小扰动公式

朝最近边界 $\hat{l}$ 做正交投影，得到本步扰动：

$$\mathbf{r}_i = \frac{|f'_{\hat{l}}|}{\|\mathbf{w}'_{\hat{l}}\|_2^2} \mathbf{w}'_{\hat{l}}$$

然后更新 $\mathbf{x}_{i+1} = \mathbf{x}_i + \mathbf{r}_i$ ，重复直到类别改变。

最终累计扰动并做**过冲**（overshoot），确保确实越过边界：

$$\hat{\mathbf{r}} = (1 + \eta) \sum_i \mathbf{r}_i, \quad \eta = 0.02.$$

过冲系数 1.02 让扰动“多推一点点”，避免样本卡在边界上、因数值/量化又被推回正确类。

本章内容

- 1 背景与动机
- 2 核心思想（几何直觉）
- 3 数学推导
- 4 算法与实现**
- 5 实验效果与对比
- 6 讨论与总结

算法伪代码（多分类 DeepFool）

- ① 初始化 $\mathbf{x}_0 \leftarrow \mathbf{x}$, $i \leftarrow 0$
- ② **while** $\hat{k}(\mathbf{x}_i) = \hat{k}(\mathbf{x}_0)$ **do**
- ③ **for** $k \neq \hat{k}(\mathbf{x}_0)$: $\mathbf{w}'_k \leftarrow \nabla f_k(\mathbf{x}_i) - \nabla f_{\hat{k}(\mathbf{x}_0)}(\mathbf{x}_i)$, $f'_k \leftarrow f_k(\mathbf{x}_i) - f_{\hat{k}(\mathbf{x}_0)}(\mathbf{x}_i)$
- ④ 选最近边界 $\hat{l} \leftarrow \arg \min_{k \neq \hat{k}(\mathbf{x}_0)} \frac{|f'_k|}{\|\mathbf{w}'_k\|_2}$
- ⑤ $\mathbf{r}_i \leftarrow \frac{|f'_{\hat{l}}|}{\|\mathbf{w}'_{\hat{l}}\|_2^2} \mathbf{w}'_{\hat{l}}$, $\mathbf{x}_{i+1} \leftarrow \mathbf{x}_i + \mathbf{r}_i$, $i \leftarrow i + 1$
- ⑥ **end while**
- ⑦ **return** $\hat{\mathbf{r}} = (1 + \eta) \sum_i \mathbf{r}_i$

复杂度主要来自每步对 c 个类别求梯度；CIFAR-10 ($c = 10$) 规模下很快。

- **过冲系数** $\eta = 0.02$ ：保证越界，缓解“边界样本被量化推回”的问题。
- **终止条件**：标签改变即停；另设最大迭代次数（如 50）防止极少数不收敛。
- **范数选择**：默认 L_2 ；可推广到 L_∞ 等 L_p 范数（改投影方式）。
- **无定向攻击**：只保证“分错成某个其他类”，不能指定目标类。
- **数值实现**：把图像当作向量，逐步累加 $\mathbf{r}_i$ ，最后裁剪到合法像素区间 $[0, 1]$ 。

常用工具

可直接用 `torchattacks`、`Foolbox`、`ART` 等库调用 `DeepFool`，几行即可跑通。

本章内容

- 1 背景与动机
- 2 核心思想（几何直觉）
- 3 数学推导
- 4 算法与实现
- 5 实验效果与对比**
- 6 讨论与总结

论文用**平均相对扰动**衡量模型的鲁棒性：

$$\hat{\rho}_{\text{adv}}(\mathbf{f}) = \frac{1}{|\mathcal{D}|} \sum_{\mathbf{x} \in \mathcal{D}} \frac{\|\hat{\mathbf{r}}(\mathbf{x})\|_2}{\|\mathbf{x}\|_2}.$$

- 分子：DeepFool 找到的最小扰动范数；分母：原图范数（归一化）。
- $\hat{\rho}_{\text{adv}}$ **越小**，说明只需更小扰动即可骗过模型 $\Rightarrow$ 模型越脆弱。
- 它给出了一个**与攻击者超参无关的**、可比较的鲁棒性数值。

与 FGSM 的对比

方法	步数	扰动范数	骗过率	是否需调参
FGSM	单步	大	高	需手调 ϵ
DeepFool	迭代 (2-4)	小 (约 FGSM 的 1/5)	相当	无需

关键结论

论文报告：DeepFool 扰动范数约为 FGSM 的 **1/5** (ImageNet 上约 1/10)，骗过率相当。

本项目实测 (下一节)：在 ResNet-18/CIFAR-10 上，DeepFool 平均 L_2 仅为 FGSM 的约 **1/11** (0.16 vs 1.72)，骗过率几乎一致。

本项目实验设置


- **模型：** ResNet-18，在 CIFAR-10 (32×32 原生分辨率) 上微调。干净测试准确率 **88.53%** (Top-3 98.14%)。
- **攻击实现：** torchattacks，全部在 $[0, 1]$ 像素空间进行，归一化包进模型（避免 clamp 破坏对抗样本）。
- **DeepFool 配置：** steps=20, overshoot=0.02，取 200 个测试样本评估。
- **对照攻击：** FGSM、APGD（均 L_∞ ， $\varepsilon = 8/255$ ），统一画扰动分布 / 混淆矩阵 / t-SNE。
- **口径：** 报告**条件攻击成功率**（只统计干净分对、被攻击翻掉的样本），并配对给出 Clean / Robust Acc。

实测结果：三种攻击对比（普通模型，白盒）

攻击	范数 / 预算	攻击成功率	Robust Acc	平均 L_2
FGSM	L_∞ , 8/255	97.91%	1.88%	1.7208
DeepFool	L_2 (最小扰动)	97.21%	2.50%	0.1604
APGD	L_∞ , 8/255	100.00%	0.00%	1.3048

- DeepFool 的平均 L_2 仅 **0.16**，约为 FGSM (1.72) 的 **1/11**、APGD (1.30) 的 1/8。
- 三者骗过率都很高，但 DeepFool 用**小一个量级**的扰动达成同样效果。
- 干净准确率均为 89.69%（200 样本子集口径）。

实测结果：扰动大小分布 (FGSM vs DeepFool)




DeepFool 的 L_2 扰动集中在接近 0 的位置，整体分布远在 FGSM 左侧——这正是“最小扰动”路线的直接证据。

实测结果：混淆矩阵（对抗样本上）


FGSM

FGSM: Confusion Matrix on Adversarial Samples
(adv accuracy = 1.9%, adv error = 98.1%)




DeepFool

DeepFool: Confusion Matrix on Adversarial Samples
(adv accuracy = 2.5%, adv error = 97.5%)



实测结果：特征空间 t-SNE (Clean vs 对抗)

t-SNE by class: Clean vs FGSM vs DeepFool vs APGD (shared embedding)



共享嵌入下，干净样本按类别聚成清晰簇；对抗样本（FGSM/DeepFool/APGD）则被打散、跨越到其他类别的区域，直观展示决策被改写。

本章内容

- 1 背景与动机
- 2 核心思想（几何直觉）
- 3 数学推导
- 4 算法与实现
- 5 实验效果与对比
- 6 讨论与总结**

优点与局限

优点

- 扰动**最小**、几乎不可见
- **无需手调**超参数
- 迭代少、**速度快**
- 几何直觉清晰、**易讲解**
- 提供可比的鲁棒性度量

局限

- 默认**无定向**（不能指定目标类）
- 扰动卡在边界，较**“脆”**（易被量化/压缩抵消，靠过冲缓解）
- 纯攻击**强度**略逊于 C&W
- 不专门对抗**有防御**的模型

与其他攻击方法的关系

方法	思路	特点
FGSM	沿梯度符号走一步	单步、 L_∞ 、扰动大
PGD	在 ϵ 球内迭代最大化损失	迭代、 L_∞ 、很强
DeepFool	投影到最近决策边界	迭代、最小扰动、快、几何
C&W	优化最小 L_2 扰动	最强、扰动极小、较慢

- DeepFool 与 C&W 同属“**最小扰动**”路线，但 DeepFool 更快、更直观。
- FGSM / PGD 属“**固定预算**”路线，关注在给定 ϵ 内的破坏力。

- **鲁棒性评估：** 用平均/中位 L_2 （或 $\hat{\rho}_{\text{adv}}$ ）比较不同模型到决策边界的距离——这是 DeepFool 的主要用途。
- **决策边界分析：** 扰动方向揭示了样本最易被推向哪个相邻类别（见混淆矩阵）。
- **不适合用于对抗训练：** DeepFool 求**最小扰动、刚越界就停**，样本“贴在边界上”、很弱，且每个样本扰动大小不一、**没有统一预算**。

本项目的做法

训练用 **PGD-AT**（固定 ϵ 内最大化损失，给“最坏情况”样本），DeepFool 只作**评估**。实测对抗训练后，鲁棒模型在 APGD 下 Robust Acc 从 0% 升到 17%（代价是干净准确率降到 72.8%）。

一句话

DeepFool = “反复把样本沿垂直方向，推到**最近**的决策边界外，所需的**最小**扰动”。

- ① **动机**: FGSM 扰动粗糙、需调参 $\Rightarrow$ 求最小扰动。
- ② **核心**: 局部线性化, 边界视为超平面, 做正交投影。
- ③ **推导**: 二分类闭式解 $\rightarrow$ 迭代 $\rightarrow$ 多分类选最近边界。
- ④ **效果**: 扰动约为 FGSM 的 $1/5$, 骗过率相当, 迭代少、速度快。

-  S.-M. Moosavi-Dezfooli, A. Fawzi, P. Frossard. DeepFool: a simple and accurate method to fool deep neural networks. CVPR 2016.
-  I. Goodfellow, J. Shlens, C. Szegedy. Explaining and Harnessing Adversarial Examples. ICLR 2015.
-  A. Madry, A. Makelov, L. Schmidt, D. Tsipras, A. Vladu. Towards Deep Learning Models Resistant to Adversarial Attacks. ICLR 2018.
-  N. Carlini, D. Wagner. Towards Evaluating the Robustness of Neural Networks. IEEE S&P 2017.

谢谢！

欢迎提问与讨论