



对抗攻击与对抗训练实验报告

基于 CIFAR-10 图像分类的对抗攻击与防御研究

王军 梁利国 汤付伟

Co-authored with Claude Opus 4.8

June 29, 2026



目录

- 1 背景与实验目标
- 2 模型训练
- 3 DeepFool 攻击方法
- 4 攻击实验与结果
- 5 对抗训练（防御）
- 6 讨论与总结



本章内容

- 1 背景与实验目标
- 2 模型训练
- 3 DeepFool 攻击方法
- 4 攻击实验与结果
- 5 对抗训练（防御）
- 6 讨论与总结

什么是对抗样本?

核心现象

对于一张可被模型正确分类的图像，叠加一个**人眼几乎察觉不到的微小扰动**，模型可能以高置信度产生错误分类。这个被扰动后的图像称为**对抗样本**。

- 扰动 $\mathbf{r}$ 幅度较小: $\|\mathbf{r}\|$ 接近 0，视觉上与原图差异极小。
- 但模型输出 $\hat{k}(\mathbf{x} + \mathbf{r}) \neq \hat{k}(\mathbf{x})$ 。
- 说明深度网络的决策边界在高维空间中可能距离正常样本较近。

研究意义： 评估模型鲁棒性、理解决策边界、改进训练（对抗训练）。

本次实验的三条主线

① 训练模型

在 CIFAR-10 上微调 ResNet-18, 得到一个准确的**基线模型**, 作为被攻击对象。

② DeepFool 攻击

(核心) 用最小扰动诱导基线模型产生误分类, 并与 FGSM / APGD 对比。

③ 对抗训练

用 PGD 对抗训练得到**鲁棒模型**, 系统评估防御策略的有效性。

训练基线模型

DeepFool 攻击

对抗训练 + 评估



本章内容

- 1 背景与实验目标
- 2 模型训练**
- 3 DeepFool 攻击方法
- 4 攻击实验与结果
- 5 对抗训练（防御）
- 6 讨论与总结



数据集与预处理

CIFAR-10: 10 类自然图像, 原生 32×32 。

- 训练 / 验证 / 测试 = **45000 / 5000 / 10000**
- 数据增广: RandomCrop(32, padding=4) + RandomHorizontalFlip
- 归一化: 均值 [0.485, 0.456, 0.406], 标准差 [0.229, 0.224, 0.225]
- 攻击阶段图像保持在 $[0, 1]$ 像素空间, **归一化集成到模型内部** (避免攻击库的 $\text{clamp}(0, 1)$ 破坏对抗样本)。

归一化集成到模型中的原因

攻击需要在合法像素区间 $[0, 1]$ 内裁剪。若先归一化再攻击, $\text{clamp}(0, 1)$ 会截断归一化后的负值, 破坏图像表示。统一约定: **数据 $[0, 1]$, 归一化作为模型第一层。**



模型结构：CIFAR 版 ResNet-18

直接使用 ImageNet 版 ResNet-18 会在网络初始阶段将 32×32 下采样至 8×8 ，造成较明显的空间信息损失。因此需做两处**适配小图**的改造：

- conv1: 7×7 stride 2 $\rightarrow 3 \times 3$ **stride 1, padding 1**
- maxpool: $\rightarrow$ **Identity (去掉)**
- fc: 输出维度改为 **10 类**
- 参数量 ≈ 11.2 M，从零开始训练。

为什么不用预训练 ResNet-18

- **stem 已调整**：预训练的 7×7 conv1 + maxpool 是为 224×224 大图设计的，将其替换为 3×3 、去掉 maxpool 后，**权重张量形状不匹配**，stem 无法直接加载。
- **迁移收益有限**：ImageNet 的高分辨率纹理特征对 32×32 小图收益有限。
- **无对抗训练基线**：从零训练得到**纯 CIFAR** 模型，避免迁移学习的混杂因素干扰后续**对抗鲁棒性**结论；4.5 万训练样本也足以从零训练至约 88 ~ 89%。



训练配置与结果

训练配置



- 损失：交叉熵
- 优化器：Adam, $lr = 10^{-3}$, weight decay = 10^{-4}
- 学习率调度：StepLR (每 5 轮 $\times 0.1$)
- 早停：验证准确率连续 **5** 轮不提升即停
- 最多 30 轮 (早停自动截断)

结果 (实际训练 **19** 轮, 早停于第 17 轮取最佳)

指标	数值
最佳验证准确率	88.96%
测试 Top-1 准确率	88.53%
测试 Macro-F1	88.50%

该模型作为后续所有攻击 / 防御实验的**基线 (普通模型)**。

训练曲线 (Loss / Accuracy)



约第 6 轮 (StepLR 首次衰减) 后曲线明显跃升并迅速收敛; 验证准确率在第 17 轮达到峰值 **88.96%**, 此后连续 5 轮无提升触发早停 (虚线处为最佳轮)。



本章内容

- 1 背景与实验目标
- 2 模型训练
- 3 DeepFool 攻击方法**
- 4 攻击实验与结果
- 5 对抗训练（防御）
- 6 讨论与总结



对抗攻击的形式化定义

对于分类器 f 与样本 $\mathbf{x}$ ，记其预测标签

$$\hat{k}(\mathbf{x}) = \arg \max_k f_k(\mathbf{x}).$$

寻找“最小”对抗扰动可写成优化问题：

$$\Delta(\mathbf{x}; f) := \min_{\mathbf{r}} \|\mathbf{r}\|_2 \quad \text{s.t.} \quad \hat{k}(\mathbf{x} + \mathbf{r}) \neq \hat{k}(\mathbf{x}), \quad \mathbf{x} + \mathbf{r} \in [0, 1]^d.$$

- $\Delta(\mathbf{x}; f)$ 度量了样本 $\mathbf{x}$ 到**决策边界**的距离。
- 该距离越小，表示模型在该样本附近的鲁棒性越低。
- **DeepFool 的目标：** 高效、准确地求解这个最小扰动。



回顾 FGSM 及其局限

经典攻击方法 FGSM (Fast Gradient Sign Method) 执行单步更新:

$$\mathbf{r} = \varepsilon \cdot \text{sign}(\nabla_{\mathbf{x}} J(\theta, \mathbf{x}, y)).$$


- **优点:** 单步计算、效率较高, 方向解释明确 (沿损失上升最快方向更新)。
- **局限一:** 取 sign 会将每个像素维度的扰动推至 $\pm\varepsilon$, 扰动**较粗糙且偏大**。
- **局限二:** 不是为“最小扰动”设计的, ε 需要**人工设定**。

由此引出 DeepFool

能否减少人工参数调节, 自动找到**恰好跨越决策边界**的最小扰动?

几何直觉：决策边界的局部超平面近似

- 在样本附近，把分类器**局部线性化**，决策边界近似为一个个**超平面**。
- 若要使样本改变类别，扰动范数最小的方向通常对应于到**最近边界**的**垂直方向**。
- 这对应于“点到平面的最短距离”这一线性代数经典问题。



在所有相邻类别的边界中，DeepFool 选择**最近**的边界，并进行垂直投影。



二分类：线性分类器（基本情形）

设二分类器 $f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b$ ，预测 $\hat{k}(\mathbf{x}) = \text{sign}(f(\mathbf{x}))$ 。

样本 $\mathbf{x}$ 到超平面 $\{\mathbf{x} : f(\mathbf{x}) = 0\}$ 的最小扰动可由**正交投影**得到：

$$\mathbf{r}_*(\mathbf{x}) = - \frac{f(\mathbf{x})}{\|\mathbf{w}\|_2^2} \mathbf{w}$$

- 方向：沿法向量 $\mathbf{w}$ （边界的垂直方向）。
- 大小： $\|\mathbf{r}_*\|_2 = \frac{|f(\mathbf{x})|}{\|\mathbf{w}\|_2}$ ，对应于**点到平面的距离**。
- 这是可直接计算的闭式解。



二分类：一般（非线性）分类器

实际神经网络通常是非线性的，没有全局超平面。DeepFool 的做法是：**反复线性化 + 迭代**。

在当前迭代点 $\mathbf{x}_i$ 把 f 一阶展开：

$$f(\mathbf{x}_i + \mathbf{r}) \approx f(\mathbf{x}_i) + \nabla f(\mathbf{x}_i)^\top \mathbf{r}.$$

令其等于 0，得到当前迭代步的最小扰动：

$$\mathbf{r}_i = - \frac{f(\mathbf{x}_i)}{\|\nabla f(\mathbf{x}_i)\|_2^2} \nabla f(\mathbf{x}_i), \quad \mathbf{x}_{i+1} = \mathbf{x}_i + \mathbf{r}_i.$$

- 每次迭代都重新计算梯度（重新线性化），逐步逼近真实弯曲的边界。
- 直到 $\hat{k}(\mathbf{x}_i)$ 改变为止，通常只需 **2-4 步**。



多分类：在所有边界中选最近的一条

对 c 类分类器 $f: \mathbb{R}^n \rightarrow \mathbb{R}^c$ ，记原始标签 $\hat{k}(\mathbf{x}_0)$ 。在迭代点 $\mathbf{x}_i$ ，对每个其他类别 $k \neq \hat{k}(\mathbf{x}_0)$ 定义：

$$\mathbf{w}'_k = \nabla f_k(\mathbf{x}_i) - \nabla f_{\hat{k}(\mathbf{x}_0)}(\mathbf{x}_i), \quad f'_k = f_k(\mathbf{x}_i) - f_{\hat{k}(\mathbf{x}_0)}(\mathbf{x}_i).$$

- $\mathbf{w}'_k$ ：类别 k 与当前类之间“等分边界”的法向。
- f'_k ：当前点相对该边界的“带符号距离量”。

选出**最近**的边界：

$$\hat{l} = \arg \min_{k \neq \hat{k}(\mathbf{x}_0)} \frac{|f'_k|}{\|\mathbf{w}'_k\|_2}.$$



多分类：最小扰动公式

朝最近边界 $\hat{l}$ 做正交投影，得到本步扰动：

$$\mathbf{r}_i = \frac{|f'_{\hat{l}}|}{\|\mathbf{w}'_{\hat{l}}\|_2^2} \mathbf{w}'_{\hat{l}}$$

随后更新 $\mathbf{x}_{i+1} = \mathbf{x}_i + \mathbf{r}_i$ ，重复该过程直到类别改变。

最终累计扰动并做**过冲**（overshoot），确保确实越过边界：

$$\hat{\mathbf{r}} = (1 + \eta) \sum_i \mathbf{r}_i, \quad \eta = 0.02.$$

过冲系数 1.02 使扰动略微越过边界，避免样本停留在边界附近，并因数值误差或量化影响仍被判为原类别。

算法伪代码（多分类 DeepFool）

- 1 初始化 $\mathbf{x}_0 \leftarrow \mathbf{x}$, $i \leftarrow 0$
- 2 **while** $\hat{k}(\mathbf{x}_i) = \hat{k}(\mathbf{x}_0)$ **do**
- 3 **for** $k \neq \hat{k}(\mathbf{x}_0)$: $\mathbf{w}'_k \leftarrow \nabla f_k(\mathbf{x}_i) - \nabla f_{\hat{k}(\mathbf{x}_0)}(\mathbf{x}_i)$, $f'_k \leftarrow f_k(\mathbf{x}_i) - f_{\hat{k}(\mathbf{x}_0)}(\mathbf{x}_i)$
- 4 选择最近边界 $\hat{l} \leftarrow \arg \min_{k \neq \hat{k}(\mathbf{x}_0)} \frac{|f'_k|}{\|\mathbf{w}'_k\|_2}$
- 5 $\mathbf{r}_i \leftarrow \frac{|f'_l|}{\|\mathbf{w}'_l\|_2^2} \mathbf{w}'_l$, $\mathbf{x}_{i+1} \leftarrow \mathbf{x}_i + \mathbf{r}_i$, $i \leftarrow i + 1$
- 6 **end while**
- 7 **return** $\hat{\mathbf{r}} = (1 + \eta) \sum_i \mathbf{r}_i$

复杂度主要来自每步对 c 个类别求梯度；在 CIFAR-10 ($c = 10$) 规模下计算开销可控。本实验用 `torchattacks.DeepFool(steps=20, overshoot=0.02)`。



本章内容

- 1 背景与实验目标
- 2 模型训练
- 3 DeepFool 攻击方法
- 4 攻击实验与结果**
- 5 对抗训练（防御）
- 6 讨论与总结



鲁棒性度量与实验设置

最小扰动攻击的核心指标不是“成功率”，而是**平均/中位 L_2 扰动**——数值越小，表示模型鲁棒性越低。 本实验采用**平均相对扰动**：

$$\hat{\rho}_{\text{adv}}(\mathbf{f}) = \frac{1}{|\mathcal{D}|} \sum_{\mathbf{x} \in \mathcal{D}} \frac{\|\hat{\mathbf{r}}(\mathbf{x})\|_2}{\|\mathbf{x}\|_2}.$$


- **被攻击模型：** 上一节训练得到的 ResNet-18（干净准确率 88.53%）。
- **评测样本：** FGSM / APGD 的指标（Acc / 成功率 / L_2 / $\hat{\rho}_{\text{adv}}$ ）基于**完整测试集 10000 张**； DeepFool 计算成本较高，采用 **1000 张**；**可视化结果**的采样设置（分布用 1000、t-SNE 用 200、混淆矩阵）见各图注。
- **对照攻击：** FGSM、APGD（均 L_∞ ， $\varepsilon = 8/255$ ）。
- **成功率定义：** **条件攻击成功率** = 干净样本上分类正确、经攻击后变为误分类的比例。

实测结果：三种攻击对比（普通模型，白盒）

攻击	范数 / 预算	攻击成功率	Robust Acc	平均 L_2	$\hat{\rho}_{adv}$
FGSM	L_∞ , 8/255	96.01%	3.57%	1.7233	0.0628
DeepFool	L_2 (最小扰动)	97.60%	2.15%	0.1606	0.0057
APGD	L_∞ , 8/255	100.00%	0.00%	1.2876	0.0467


- DeepFool 的相对扰动 $\hat{\rho}_{adv}$ 仅 **0.0057**，约为 FGSM (0.063) 的 $1/11$ 、APGD (0.047) 的 $1/8$ ；平均 L_2 (0.16) 同样低一个量级。
- 三者攻击成功率都较高，但 DeepFool 以**低一个量级**的扰动达到相近效果。
- **样本量**：FGSM / APGD 使用**完整测试集 10000 张**，DeepFool 因计算成本较高采用 **1000 张**；干净准确率 FGSM/APGD 为 88.53%、DeepFool 为 89.65%（同一模型，不同评估子集）。

对抗样本可视化：人眼难以察觉，模型发生误分类



以 **DeepFool** 为例（每行一个样例，取 2 例）：左为**原图**，模型正确分类；中为叠加最小扰动后的**对抗图**，模型以高置信度**预测为相邻类别**；右为**放大显示**的扰动（真实幅度 $L_2 \approx 0.16$ ，肉眼几乎不可见）。该结果表明：**决策边界可能距离正常样本较近**。

实测结果：扰动大小分布 (FGSM vs DeepFool)




DeepFool 的 L_2 扰动集中在接近 0 的位置，整体分布远在 FGSM 左侧——这是“最小扰动”评估范式的实证体现。

实测结果：混淆矩阵（对抗样本上）


FGSM

FGSM: Confusion Matrix on Adversarial Samples
(adv accuracy = 1.9%, adv error = 98.1%)





DeepFool

DeepFool: Confusion Matrix on Adversarial Samples
(adv accuracy = 2.5%, adv error = 97.5%)





对角线（仍分类正确）显著减弱：两种攻击都将大量样本推向**相邻类别**，但 DeepFool 所需扰动更小。

实测结果：特征空间 t-SNE (Clean vs FGSM)



四张 t-SNE 共享同一嵌入（坐标可比）。左：Clean 按 10 个真实类别聚成清晰簇；右：FGSM (L_∞) 显著扰动原有聚类结构，并将样本推向其他类别区域，直观展示决策结果的变化。

实测结果：特征空间 t-SNE (DeepFool vs APGD)



与 Clean/FGSM 页使用同一嵌入。DeepFool 与 APGD 均改变类别簇结构；DeepFool 的扰动规模显著更小（见 $L_2/\hat{\rho}_{adv}$ ）。



本章内容

- 1 背景与实验目标
- 2 模型训练
- 3 DeepFool 攻击方法
- 4 攻击实验与结果
- 5 对抗训练（防御）**
- 6 讨论与总结



对抗训练：使用最坏情形样本训练模型

防御方法：训练时**先用 PGD 为每批干净样本在线生成对抗样本**，再用其（标签仍为原始 y ）训练，促使模型在受攻击条件下仍保持正确分类。形式化为**min-max（鞍点）问题**：

$$\min_{\theta} \mathbb{E}_{(\mathbf{x}, y)} \left[\max_{\|\delta\|_{\infty} \leq \epsilon} L(f_{\theta}(\mathbf{x} + \delta), y) \right].$$

- **内层 max**：在预算 ϵ 内寻找使损失最大的扰动（用 PGD 近似）。
- **外层 min**：更新参数 θ ，降低“最坏情况”损失，从而提升鲁棒性。
- 对抗样本**在线生成**：模型参数持续更新，因此需基于当前模型重新执行 PGD。



PGD: 求解内层 $\max$ 的迭代攻击

PGD (Projected Gradient Descent) = **多步 FGSM + 投影**, 用来近似内层 $\max$ ——在 ε 预算内寻找使损失最大的“最坏扰动”:

$$\mathbf{x}^{t+1} = \Pi_{\mathcal{B}_\varepsilon(\mathbf{x})}(\mathbf{x}^t + \alpha \operatorname{sign}(\nabla_{\mathbf{x}} L(\theta, \mathbf{x}^t, y))), \quad t = 0, 1, \dots, K-1.$$

- **随机起点:** $\mathbf{x}^0 = \mathbf{x} + \operatorname{Uniform}(-\varepsilon, \varepsilon)$, 避免每次从同一点出发、削弱梯度混淆。
- **投影 Π :** 每步把结果裁回 L_∞ 球 ($\|\mathbf{x}^t - \mathbf{x}\|_\infty \leq \varepsilon$) 并保持 $\mathbf{x}^t \in [0, 1]$ 。
- **步长 α 、步数 K :** 训练用 **PGD-7** ($\alpha = 2.5\varepsilon/K \approx 0.36\varepsilon$) ; 评估用更强的 **PGD-20** ($\alpha = 2/255$, 随机重启)。

与 FGSM (单步将扰动推至 $\pm\varepsilon$) 相比, PGD 在预算内**迭代增加损失**, 生成的高损失对抗样本攻击强度更高, 符合对抗训练内层 $\max$ 的目标。



为什么用 PGD，而不是 DeepFool?

PGD (用于训练)

在**固定预算 ϵ 内最大化损失** $\rightarrow$ 提供“最坏情况”样本，与内层 $\max L$ 的优化目标一致。
因此适合用于提升固定扰动预算下的鲁棒性。

DeepFool (不用于训练)

求**最小扰动、达到类别改变即停止** $\rightarrow$ 样本通常位于边界附近，攻击强度有限，且每个样本扰动大小不一、**没有统一预算**。
因此不适合作为固定预算对抗训练的内层攻击。

结论

PGD 同时用于训练与评估；**DeepFool** 是**评估工具**（用于测量最小扰动大小，并估计样本到决策边界的距离）。




PGD 对抗训练实验设置

- 训练集：完整训练集 50000 张，原生 32×32 + 增广
- 内层攻击：**PGD-7**, L_∞ , $\epsilon = 8/255$
- ϵ 预热：前 5 轮从 0.5ϵ 线性升到 ϵ
- 损失： $(1 - \lambda) CE_{\text{clean}} + \lambda CE_{\text{adv}}$, $\lambda = 0.5$ (保留干净样本性能, **降低性能退化风险**)
- 优化器：SGD ($lr = 0.1$, $mom = 0.9$, $wd = 5 \times 10^{-4}$)
- 调度：MultiStepLR 在 40 / 60 轮 $\div 10$, 共 **80** 轮
- 梯度裁剪：上限 1.0

鲁棒性评估控制项

- 干净/对抗损失**各半**，降低模型性能退化风险 (Clean/Robust 双低)。
- 评估采用**高强度攻击** (APGD)，并按强度阶梯 $FGSM < PGD-20 < APGD$ 检查梯度混淆。
- Clean Acc 与 Robust Acc **联合报告**。

对抗训练曲线 (Loss / Clean Acc / Adv Acc)



共 80 轮, MultiStepLR 在第 40 / 60 轮 $\div 10$: 每次衰减后 Clean 与 Adv Acc 都明显跃升, 最终 Clean $\approx 99.5\%$ 、Adv (PGD-7 训练态) $\approx 61.8\%$, loss 平稳下降且无明显震荡, 训练过程收敛稳定。

防御效果：普通模型 vs 鲁棒模型

攻击强度阶梯：FGSM（较低强度）< PGD-20（标准基准）< APGD（高强度）。同一模型 Robust Acc 应**依次递减**；DeepFool 为**无 ϵ 预算**的最小扰动攻击，单列作对照。


	Clean Acc	FGSM	PGD-20	APGD	DeepFool
普通模型	88.53%	3.57%	0.00%	0.00%	2.2%
鲁棒模型	86.25%	55.62%	45.82%	45.30%	0.9%

结果解读：对抗训练有效时，鲁棒模型在三种**固定 ϵ** 攻击下 Robust Acc 应明显更高，代价是 Clean 略降。本实验 Clean 降 2.3 点（88.53%→86.25%），换来 Robust Acc 由接近 0 升至 **45-56%**，未出现明显性能退化；且沿 FGSM > PGD-20 > APGD 依次递减，未观察到梯度混淆。

DeepFool Robust Acc 均接近 0（普通 2.2%，鲁棒 0.9%）：该攻击无 ϵ 预算，通常迭代至越过决策边界才停止；其防御信号主要体现在**所需扰动大小**（ $\hat{\rho}_{adv}$ ），而非 Robust Acc。


注：FGSM/PGD-20/APGD 使用完整测试集 **10000 张**（ $L_{\infty}, \epsilon = 8/255$ ）；DeepFool（ L_2 最小扰动）使用 **1000 张**。

防御效果：普通模型 vs 鲁棒模型（图示）



对抗训练后，鲁棒模型在 FGSM / PGD-20 / APGD 三种**固定** ϵ 攻击下 Robust Acc 由接近 0 升至 **45–56%**（完整测试集 10000 张），代价是 Clean 降约 2.3 点（88.53% $\rightarrow$ 86.25%），且沿强度阶梯依次递减，未观察到梯度混淆。图中 **DeepFool**（无 ϵ 预算）仅作为最小扰动攻击对照；其防御效果需结合**所需扰动大小**（ $\hat{\rho}_{adv}$ ）进行分析。

防御效果：DeepFool 最小扰动（边界距离视角）



DeepFool 求解**最小扰动**，其大小可近似表示样本到决策边界的距离；数值越大，模型鲁棒性越强。

- 普通模
型： $\hat{\rho}_{adv} \approx \mathbf{0.006}$ ($L_2 \approx 0.18$) 。
- 鲁棒模
型： $\hat{\rho}_{adv} \approx \mathbf{0.043}$ ($L_2 \approx 1.22$) 。
- 诱导鲁棒模型产生误分类需要 $\sim \mathbf{7}$
倍大的扰动。

与固定预算评估范式（Robust Acc）互
补：从**边界距离**角度同样证明对抗训练有
效。

（1000 张，仅统计干净样本上分类正确且经攻
击后变为误分类的样本；普通模型 L_2 0.18 略大
于攻击对比表中的 0.16，原因是后者在
evaluate 统计方式下同时纳入未攻击成功样
本。）



本章内容

- 1 背景与实验目标
- 2 模型训练
- 3 DeepFool 攻击方法
- 4 攻击实验与结果
- 5 对抗训练（防御）
- 6 讨论与总结**



DeepFool 的优点与局限

优点

- 扰动**最小**、几乎不可见
- **无需人工调节**关键超参数
- 迭代次数少、**计算效率较高**
- 几何直觉清晰、**便于解释**
- 提供可比的鲁棒性度量

局限

- 默认**无定向**（不能指定目标类）
- 扰动位于边界附近、**对预处理敏感**（易被量化/压缩抵消，靠过冲缓解）
- 纯攻击**强度**略逊于 C&W
- **不适合**用于对抗训练

不同攻击方法的对比

方法	核心机制	特点
FGSM	沿梯度符号执行单步更新	单步、 L_∞ 、扰动较大
PGD	在 ε 球内迭代最大化损失	迭代、 L_∞ 、用于训练与评估
APGD	自适应步长 + 重启	高强度评估基线 (AutoAttack 组件)
DeepFool	投影到最近决策边界	迭代、最小扰动、几何解释明确
C&W	优化最小 L_2 扰动	攻击强度高、扰动极小、计算成本较高

- DeepFool 与 C&W 属于 “**最小扰动**” 评估范式 (估计到决策边界的距离)。
- FGSM / PGD / APGD 属于 “**固定预算**” 评估范式 (分析给定 ε 内的攻击效果)。



总结

- 1 训练模型：** CIFAR 版 ResNet-18 (conv1 改 3×3 、去 maxpool) ， 测试准确率 **88.53%**，作为基线。
- 2 DeepFool 攻击：** 局部线性化、投影到最近决策边界，求**最小 L_2 扰动**；实测平均 L_2 仅 **0.16**，约 FGSM 的 $1/11$ ，攻击成功率相近。
- 3 对抗训练：** 用 PGD (非 DeepFool) 做 min-max 训练得到鲁棒模型；可靠评估需同时报告 Clean/Robust 指标，并采用高强度攻击 (APGD) 。

结论概括

DeepFool 可量化模型到决策边界的距离，PGD 对抗训练可提升固定扰动预算下的鲁棒性；鲁棒性评估必须采用高强度攻击，并同时报告 Clean/Robust 指标，以避免高估防御效果。

谢谢！

欢迎提问与讨论